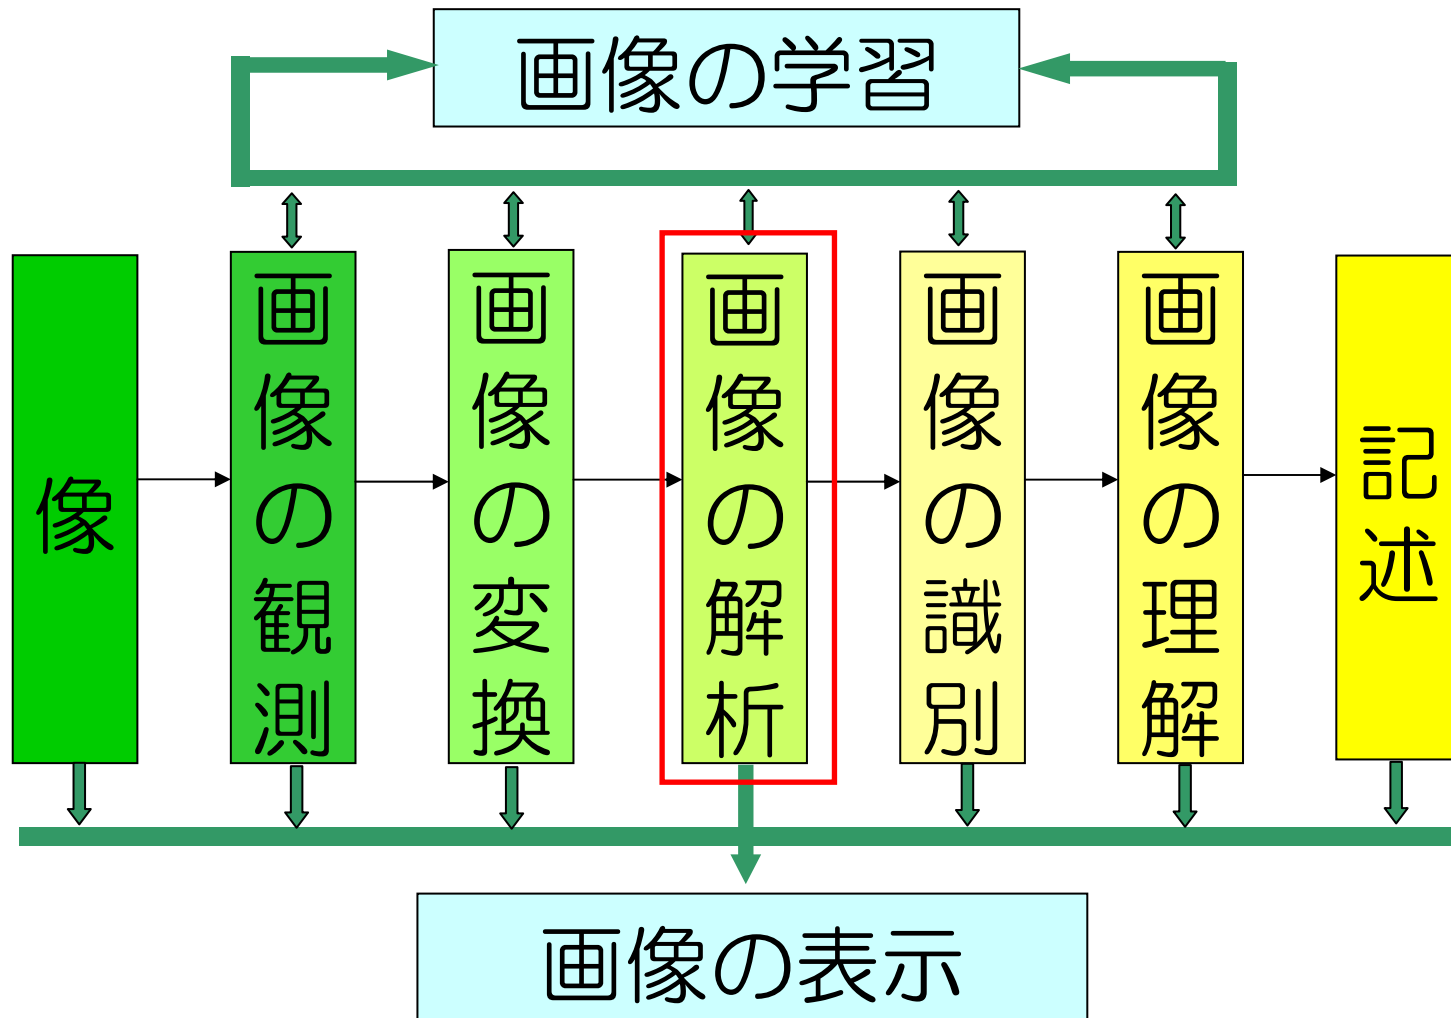


画像の特徴抽出(I)

点，線，領域，スケール

画像の処理工程



画像の分割

- 点検出

- * コーナ検出 (Harris法, KLT法, 主曲率法など)

- 線・輪郭線検出 (濃淡値の不連続部の検出)

- * エッジ強調による線検出 (Canny法, ゼロ交差法, 弛緩法, 非極値抑制法など)

- * パラメータ空間での線検出 (Hough変換)

- * 輪郭線検出 (動的輪郭法, レベルセット法など)

- 領域分割

- * 画質の均一性による画素の分類

- * テクスチャによる分類

コーナー検出(Harris/Plessey法)

各画素毎に、以下の行列 \mathbf{M} を計算

ただし、画像 L は、 $L = G \otimes f$ (f : 原画像, G : ガウス関数)

$$\mathbf{M} = \begin{bmatrix} L_x L_x & L_x L_y \\ L_x L_y & L_y L_y \end{bmatrix} = \begin{bmatrix} A & C \\ C & B \end{bmatrix},$$

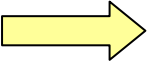
行列 \mathbf{M} の固有値を λ_1, λ_2 とするとし、各画素に対して以下のコーナーらしさ $c(x, y)$ を計算

$$c(x, y) = \det(\mathbf{M}) - k(\text{tr}(\mathbf{M}))^2, \quad k = \text{constant}$$

$$\det(\mathbf{M}) = \lambda_1 \lambda_2 = AB - C^2$$

$$\text{tr}(\mathbf{M}) = \lambda_1 + \lambda_2 = A + B$$

もし、 $c(x, y) < T$ ならば $c(x, y) = 0$

全画素処理後  $c(x, y)$ に対して非極値抑制処理を実行。
ゼロでない点をコーナーとして検出。

コーナー検出(KLT法)

各画素毎に、以下の行列 \mathbf{M} を計算

ただし、画像 L は、 $L = G \otimes f$ (f : 原画像, G : ガウス関数)

$$\mathbf{M} = \begin{bmatrix} L_x L_x & L_x L_y \\ L_x L_y & L_y L_y \end{bmatrix} = \begin{bmatrix} A & C \\ C & B \end{bmatrix},$$

行列 \mathbf{M} の固有値を以下の式から計算

$$\det(\mathbf{M} - \lambda \mathbf{I}) = 0 \quad \lambda^2 - (A + B)\lambda + AB - C^2 = 0$$

KLT法では、上式の固有値を λ_1, λ_2 とするととき、

$$\min(\lambda_1, \lambda_2) > T$$


を満たす点をコーナーとして検出。

主曲率によるコーナ検出

ヘッセ行列の固有値から得られる主曲率を用いて特徴点を検出。(Hessian法)

各画素毎に、ヘッセ行列 M を計算。 $M = \begin{bmatrix} L_{xx} & L_{xy} \\ L_{xy} & L_{yy} \end{bmatrix}$,
ただし, $L = G \otimes f$

行列 M の固有値を λ_1, λ_2 とすると, 以下のような分類が可能.




λ_1, λ_2 ともに小さい : フラット


λ_1, λ_2 ともに大きい : コーナ

$\lambda_1 \gg \lambda_2$ 或いは $\lambda_2 \gg \lambda_1$: エッジ

コーナ検出例(1/2)




ガウス核は 3×3 の
mask patternを使用.




KLT 法

$T = 8$, pointno. = 130



Harris/Plessey 法


$T = 1000$, $k = 0.04$



Hessian 法

$T = 1$, pointno. = 134


コーナ検出例(2/2)



KLT 法

$$T = 6$$

（前処理： Median Filter,
ガウス核： 5×5 マスク
特徴点数： 24 点



Harris/Plessey 法

$$T = 100, k = 0.04$$

（前処理： Median Filter,
ガウス核： 5×5 マスク
特徴点数： 27 点



エッジ強調による線検出

処理の概要

- エッジ強調画像の生成
 - 弛緩法, ゼロ交差法, Canny法
 - 非極値抑制エッジ強調法などを利用
- 閾値以上のエッジ抽出
- 断片的なエッジの連結
 - エッジ方向に基づく延長処理,
 - 線の膨張処理など

非極値抑制エッジ強調法

- 非極値抑制の概要




非極値抑制エッジ強調処理の例



原画像



エッジ伸長処理なし



エッジ伸長処理あり

線検出 (Hough変換)


- 直線のパラメータ表示

$$x \cos \theta + y \sin \theta = \rho$$

画素点 (x_i, y_i) を通る直線


(θ, ρ) 空間に写像

$$x_i \cos \theta + y_i \sin \theta = \rho$$



Hough変換

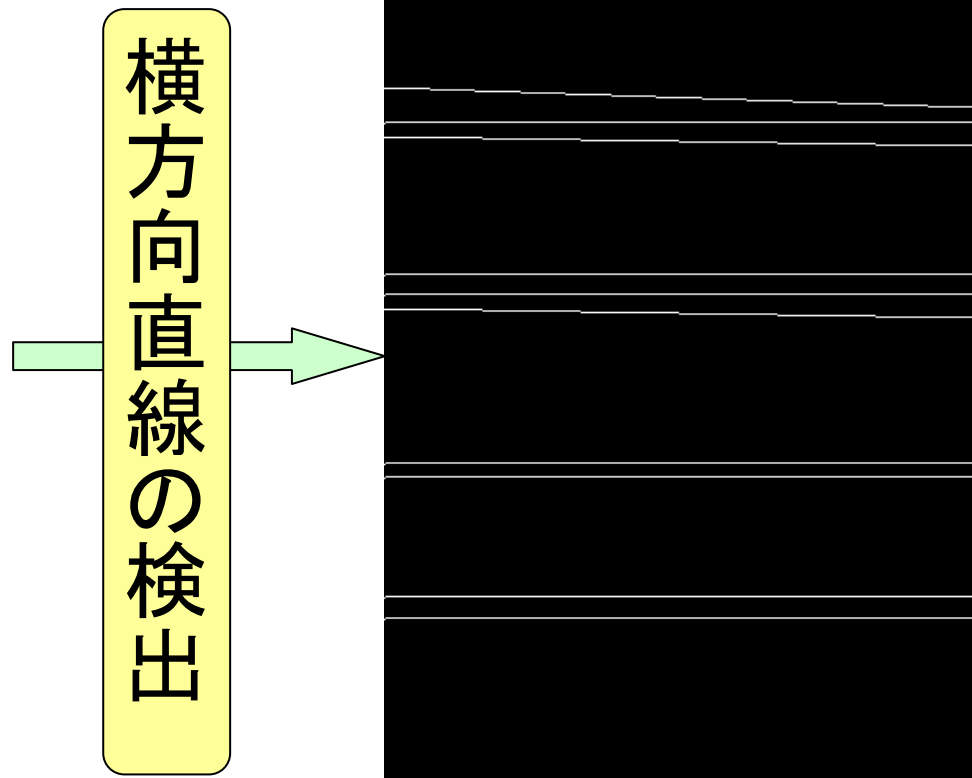
$(x_1, y_1), (x_2, y_2)$ を通る直線の (θ, ρ) 関係



Hough変換による直線検出の例



原画像の例




直線検出の例

輪郭線抽出 (SNAKES)

- 動的輪郭モデル (Active Contour Model)
エネルギー (評価関数) の導入とその最小化
輪郭線のパラメータ表現

$$v(s) = (x(s), y(s))$$



エネルギー関数 E_{snakes}

$$E_{snakes} = \int \{E_{in}(v(s)) + E_{img}(v(s)) + E_{con}(v(s))\} ds$$

E_{in} : 輪郭線の持つ内部エネルギー


E_{img} : 画像のエッジ部分で極小となるエネルギー

E_{con} : 外部からの拘束力によるエネルギー

$s(0.0 \sim 1.0)$ を離散化して輪郭上に N 個の
制御点 $v(1), \dots, v(N)$ を配置.

内部エネルギーの例

$$E_{in} = \alpha |\dot{\mathbf{v}}(s)| + \beta |\ddot{\mathbf{v}}(s)|$$




$$\dot{\mathbf{v}}(i) = \mathbf{v}(i) - \mathbf{v}(i-1)$$


$$\ddot{\mathbf{v}}(i) = \dot{\mathbf{v}}(i+1) - \dot{\mathbf{v}}(i)$$

画像エネルギーの例


$$E_{img} = -\gamma \cdot \nabla I(x, y)$$




動的輪郭線処理の例



積み木画像



初期制御点配置



収束後制御点配置

領域分割

- 基本的概念

画質の均一性とそれに基づく画素の分類

- 画質評価のための画像特性

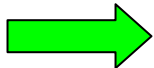
濃度, 色, テクスチャ, スペクトルなど

- 画像分割のための空間

画像空間上での分割


特徴空間上での分割

- 分割領域数

領域数2の分割  2値化処理

2値化処理

- カテゴリ数2の領域分割
- 主な手法（特徴空間上での分割）
 - * モード法
 - * 事前情報に基づく2値化法
 - * 区分的2値化法
 - * 判別分析法



- 画像に占める対象物体の
大きさの割合
 - 対象物体の色情報
-
- 画像を分割し、各ブロック毎に
2値化

判別分析法

- 領域の分離性を評価

$$\eta(t) = \frac{\sigma_I^2(t)}{\sigma_T^2(t)} \rightarrow \text{最大化 (} t \text{ を選択)}$$

$$\sigma_T^2(t) = \sigma_1^2 + \sigma_2^2 \quad (\text{クラス内分散})$$


$$\sigma_I^2(t) = \frac{n_1(m_1 - m_0)^2 + n_2(m_2 - m_0)^2}{n_1 + n_2}$$

(クラス間分散)

n_1, n_2 : 各クラスの個数

m_1, m_2 : 各クラスの平均、 m_0 : 全体平均


濃度ヒストグラム



2値化処理の例



原画像



ヒストグラム



判別分析法 →
(121)

← モード法 (108)




領域分割法

(カテゴリ数2以上)


- 分離統合による分割 (Split and Merge法)
- 非線形平滑化による分割 (ランクフィルタ等)
- 特徴空間でのクラスタリングによる分割
- 特徴空間と画像空間の再帰的分割
- 対象の知識を利用した分割
- ベイズ統計処理による分割
- Graph Cut法による分割
- 統計的手法 (MRFなど) による分割

Split and Merge法

- 画像の4進木表現




画像



中間レベルから各スクエアの均一性を評価
不均一なら分離，隣接4近傍が均一なら統合

クラスタリングによる領域分割

ある特徴空間上の点を，その分布状態に応じていくつかのグループ（クラスタ）に分類すること。



クラスタリングの例

代表的クラスタリング法

- Nearest Neighbor Algorithm(NN法)
- K Nearest Neighbor Algorithm(K-NN法)
- K Mean Algorithm(K平均法)

準備

特徴空間上の N 個の点 $\quad \quad \quad : \{P_1, P_2, \dots, P_N\}$

クラスタ c_k の代表パターン $\quad \quad \quad : C_k$

パターン P_i と P_j の距離 $\quad \quad \quad : d(P_i, P_j)$

Nearest Neighbor法

各パターン $P_l (l = 1, \dots, N)$ に対して, 次式を計算.

$$d_{\min} = \min_{1 \leq i \leq N_c} \{d(P_l, C_i)\}$$

(N_c はクラス数, C_i はクラス c_i の代表ベクトル)

- $d_{\min} \leq T$ ならば, P_l をクラス c_i に帰属させる.
- $d_{\min} > T$ ならば, P_l を新たなクラスとして生成.

(N_c をインクリメントし, $C_{N_c} = P_l$ とする.)

$d(P_l, C_i)$: パターン P_l と C_i の距離

K-Nearest Neighbor法

各パターン $P_l (l = 1, \dots, N)$ に対して次式を計算.

$$d_l(i, j) = D(P_l, C_{ij}) \quad \text{for } 1 \leq i \leq N_c, 1 \leq j \leq n$$

C_{ij} は, クラス c_i の j 番目の代表ベクトル.

クラス数, 各代表ベクトルは予め決定.

- $d_l(i, j), 1 \leq i \leq N_c, 1 \leq j \leq n$ を, 距離の順に並び替える.
- 距離の小さい順に K 個の代表ベクトルを選択.
- 選択された各代表ベクトルのクラスを調べ、最も多いクラスに P_l を帰属させる.

K-平均法(K-Mean Algorithm)

- K 個のパターンを選択し, クラスタ c_1, c_2, \dots, c_k の代表パターンとする.

- パターン P_l が,

$$d(P_l, C_i) < d(P_l, C_j), \text{ for } j = 1, \dots, K (j \neq i)$$

のとき, パターン P_l を c_i に帰属させる.

- すべてのパターンの分類後, 代表パターンを更新.

$$C_i = \frac{1}{N_i} \sum_{P_j \in c_i} P_j, \quad N_i \text{ はクラスタ } c_i \text{ に属するパターン数}$$


- 全ての代表パターンが変化しなくなるまで上記を反復.

領域分割の例

原画像



2値画像
(判別法)



K平均法による領域分割の例

 $k = 2$  $k = 3$  $k = 4$  $k = 5$  $k = 6$  $k = 7$ 

画像特徴の記述(線)

• 線の記述

- : 線の連結性: 4連結と8連結
- : 細線化処理
- : 連結性に基づく点追跡
- : 端点, 分岐点, 交差点, 連結点
- : 点列, チェーンコード, グラフ



5	6	7
4	r	0
3	2	1

8近傍

$$N_c^{(4)}(r) = \sum_{k \in S_1} (f(x_k) - f(x_k)f(x_{k+1})f(x_{k+2}))$$

$$N_c^{(8)}(r) = \sum_{k \in S_1} (\bar{f}(x_k) - \bar{f}(x_k)\bar{f}(x_{k+1})\bar{f}(x_{k+2}))$$

$$S_1 = \{0, 2, 4, 6\}$$

$$k : \text{mod } 8$$

距離速度 D

- 距離の条件

$$D(p, r) \leq D(p, q) + D(q, r)$$

(1) ユークリッド距離 (Euclidean distance)

$$D_e((i, j), (k, l)) = ((i - k)^2 + (j - l)^2)^{1/2}$$

(2) 街区画距離 (city block distance)


$$D_4((i, j), (k, l)) = |i - k| + |j - l|$$

(3) チェス距離 (chase board distance)


$$D_8((i, j), (k, l)) = \max(|i - k|, |j - l|)$$

Chain Code符号化法

Chian Code



primitive



(a,b)

start: (a,b)
chain codes: 76677670112321

画像特徴の記述 (領域)

- 位相幾何特徴表現

領域の連結数, 孔数, オイラー数

- モーメント表現

$$M_{pq} = \sum_{y=1}^N \sum_{x=1}^M x^p y^q f(x, y),$$

$$\hat{M}_{pq} = \sum_{y=1}^N \sum_{x=1}^M (x - \bar{x})^p (y - \bar{y})^q f(x, y)$$


- 領域計量表現

連結画素数, 境界画素数, 円形度, 凹率など

- 特徴抽出表現

各種直交変換, 色ヒストグラム, HOG等の利用

HOG(Histogram of Oriented Gradients)




画像 $I(x, y)$ を $n \times n$ 画素の重ならないセルに分割
($M \times N$ セル)

セル内の各画素の勾配を計算

$$m(x, y) = \sqrt{I_x^2 + I_y^2}, \quad \theta(x, y) = \tan^{-1} \frac{I_y}{I_x}$$

勾配方向の9方向量子化, セル内度数分布作成

$p \times q$ のセルを単位とし, 1セル毎にシフトしたブロックを構成



Navneet Dalal and Bill Triggs, “Histograms of Oriented Gradients for Human Detection”,
Proc. of Int. Conf. on Computer Vision and Pattern Recognition, 2005

合計： $(M - p + 1) \times (N - q + 1)$ 個のブロック

k 番目のブロックが u 行 v 列目のセルを先頭とするとき,

$$V_k = [h_{u,v}, h_{u,v+1}, \dots, h_{u,v+q-1}, h_{u+1,v}, \dots, h_{u+p-1,v}, \dots, h_{u+p-1,v+q-1}]$$

となる特徴ベクトルを作成.

($h_{u,v}$ は (u, v) 番目のセルの度数分布)

さらに特徴ベクトルを正規化


$$\tilde{h}_{i,j} = \frac{h_{i,j}}{\sqrt{\|V_k\|^2 + 1.0}}, h_{ij} \in V_k \Rightarrow \tilde{V}_k$$

(例)

画像サイズ： 72×48画素,

セルサイズ： 8×8 画素,

ブロックサイズ： 2×2セル



ブロック数： 40

特徴ベクトル次元数： 360


スケール特徴検出(1/10)

SIFT(Scale Invariant Feature Transform)で用いられている
特徴量計算.

ガウス関数のラプラシアン(Laplacian of Gaussian; LoG)

$$\nabla^2 G = G_{xx} + G_{yy} = \frac{x^2 + y^2 - 2\sigma^2}{2\pi\sigma^6} \exp\left(-\frac{x^2 + y^2}{2\sigma^2}\right)$$

$\sigma = 3.0$ の場合のグラフ



スケール特徴検出(2/10)


- 画像 $f(x, y)$ に対して, 以下の LoG 尺度空間を作成.

$$L_{\nabla^2 G}(x, y; \sigma) = \left(\nabla^2 G(x, y; \sigma) \right) \otimes f(x, y)$$

(参考)

$$L_G(x, y; \sigma) = \left(G(x, y; \sigma) \right) \otimes f(x, y)$$

$L_{\nabla^2 G}$ 尺度空間



スケール特徴検出(3/10)

スケール σ の増大



ガウス核表現に必要なマスクサイズの増大



計算時間の増大

マスク処理不整合端領域の増大

$L_{\nabla^2 G}$ 尺度空間作成の負荷軽減 減法

- (1) DoG処理によるLoG計算の近似
- (2) ガウス核平滑化とダウンサンプリングの関係を利用

スケール特徴検出(4/10)

(1) DoG処理によるLoG計算の近似

$$\begin{aligned} \frac{\partial G}{\partial \sigma} &= \frac{\partial}{\partial \sigma} \left(\frac{1}{2\pi\sigma^2} \exp\left(-\frac{x^2 + y^2}{2\sigma^2}\right) \right) \\ \text{一方, } &= \frac{x^2 + y^2 - 2\sigma^2}{2\pi\sigma^5} \exp\left(-\frac{x^2 + y^2}{2\sigma^2}\right) = \sigma(\nabla^2 G) = \sigma \cdot LoG \\ \frac{\partial G}{\partial \sigma} &= \lim_{\Delta\sigma \rightarrow 0} \frac{G(x, y; \sigma + \Delta\sigma) - G(x, y; \sigma)}{\Delta\sigma} = \lim_{k \rightarrow 1} \frac{G(x, y; k\sigma) - G(x, y; \sigma)}{(k-1)\sigma} \\ &\approx \frac{G(x, y; k_0\sigma) - G(x, y; \sigma)}{(k_0-1)\sigma}, \quad k_0(>1) \text{ は } 1 \text{ に近い定数} \end{aligned}$$


ここで, $DoG = G(x, y; k_0\sigma) - G(x, y; \sigma)$,

(Difference of Gaussian; DoG)とおくと,


$$\frac{\partial G}{\partial \sigma} = \sigma \cdot LoG \quad \text{の関係より} \quad LoG \approx \frac{DoG}{\sigma^2(k_0-1)} \longrightarrow \begin{array}{l} LoGの代わりに \\ DoGを利用 \end{array}$$

スケール特徴検出(5/10)


LoG vs. DoG



$LoG(\cdot; 3.0)$



$DoG(\cdot; 3.0, \sqrt[5]{2})$



$DoG(\cdot; 3.0, \sqrt[10]{2})$

スケール特徴検出(6/10)

DoG画像のスケールによる変化 ($\sigma_0 = 1.0, k^5 = 2.0$)



(a) $k^0 \sigma_0$



(d) $k^3 \sigma_0$



(b) $k^1 \sigma_0$



(e) $k^4 \sigma_0$



(c) $k^2 \sigma_0$



(f) $k^5 \sigma_0$

スケール特徴検出(7/10)

(2) ガウス核平滑化とダウンサンプリングの関係利用

$L_G^{(0)}(\cdot; \sigma_1) = G(\cdot; \sigma_1) \otimes f$ とし, $L_G^{(0)}(\cdot; \sigma_1)$ を $1/2$ にダウンサンプリングした画像を $L_G^{(1)}(\cdot; \sigma_1)$ とするとき,

$$L_G^{(1)}(\cdot; \sigma_1) \approx L_G^{(0)}(\cdot; 2\sigma_1)$$

一般的に $L_G^{(i+1)}(\cdot; \sigma_1) \approx L_G^{(i)}(\cdot; 2\sigma_1)$

以上のことから

σ_1 から $2\sigma_1$ の間に $\sigma_1, k\sigma_1, \dots, k^n\sigma_1 (= 2\sigma_1)$ の $(n+1)$ 個のスケールを考え, n 枚のDoG画像を生成.

$$L_{DoG}^{(i)}(\cdot; \sigma_1) = L_G^{(i)}(\cdot; k\sigma_1) - L_G^{(i)}(\cdot; \sigma_1)$$


$$L_{DoG}^{(i)}(\cdot; k\sigma_1) = L_G^{(i)}(\cdot; k^2\sigma_1) - L_G^{(i)}(\cdot; k\sigma_1)$$

$$\vdots$$

$$L_{DoG}^{(i)}(\cdot; k^{n-1}\sigma_1) = L_G^{(i)}(\cdot; k^n\sigma_1) - L_G^{(i)}(\cdot; k^{n-1}\sigma_1)$$



スケール特徴検出(8/10)

$[\sigma_1, 2\sigma_1]$ を5分割(例)



スケール特徴検出(9/10)

画素 (x, y) における σ をパラメータとする DoG 値の変化に着目.
(極値の存在)




σ_0 : 画素 (x, y) のスケール

スケール空間の因果性 に基づき、各画素毎の DoG 最大値
を与えるスケールを、 その点のスケール特徴 と定義.


スケール特徴検出(10/10)



中心点(128,128)での
DoG変化のグラフ



点(128,128)のスケールは, $\sigma = 1.4$



L_{DoG} 尺度空間により得られる画素毎のスケール特徴可視化例