


最適化のための基礎

最適化に基づく画像処理の必要性

理由

ビジョン問題では、観測時の雑音やオクルージョンに起因する不確かさが存在し、完全に正確な解を得ることは困難。



多くのビジョン問題が最適化問題として
定式化される

画像処理の最適化と統計的手法

画像処理における最適化とは、ある基準に基づいて最も良く目的を達成することを目指すもの。

統計的画像処理とは、画像の表現に統計モデルを導入し、そのモデルパラメータを推定することで、結果として目的とする画像を得る手法。

統計的画像処理手法では、MRFやGRFによるモデル化がしばしば利用される。

最適化手法における三要素

1. 問題の表現

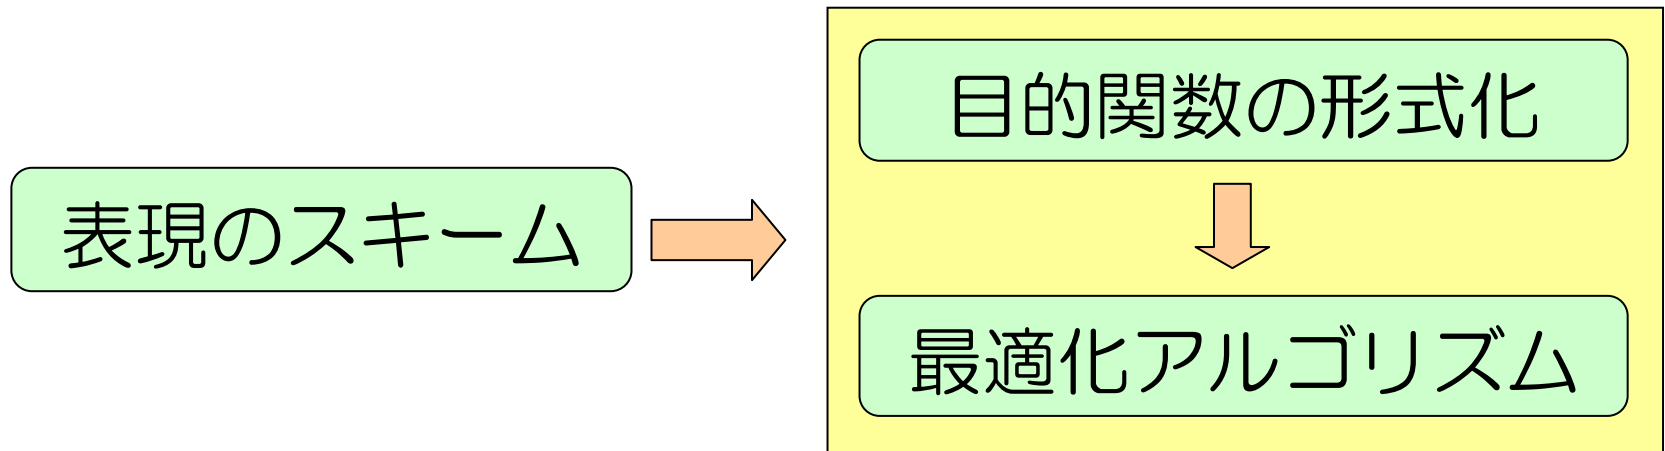
どんな特徴で解を形式化するか

2. 目的関数

最適化をどのように基準化するか

3. 最適化アルゴリズム

どのようにして最適値を探索するか



- 目的関数とその最適化法とは密接に関係.
- 目的関数としては, エネルギー関数や (対数) 尤度関数, 事後確率など.
- 最適化手法には様々な方法があって, それぞれ特徴あり.

最適化基準

データ分布のみがあり、推定量の事前情報がない

→ 最大尤度 (maximum likelihood) 推定

逆の場合

→ 最大エントロピー (maximum entropy) 推定

推定量の事前情報とデータ分布がともに既知

→ Bayes基準

最大事後確率 (maximum a posterior; MAP) 推定

最大事後確率平均 (maximum a posterior mean;) 推定

エネルギー関数

エネルギー関数の役割

1. 解の大局性を定量的に表現.
2. 最小解に対する探索の指針を提供.

エネルギー関数の定式化

基本的方法 $\begin{cases} \text{パラメトリックな表現} \\ \text{ノンパラメトリックな表現} \end{cases}$

最小解 f^* : 関数形式 E とパラメータ θ に依存

$$f^* = \arg \min_f E(f \mid \mathbf{d}, \theta) \quad \mathbf{d} \text{ は観測データ}$$

事象・集合・確率

- ある操作を行うこと： 試行
- 試行によって起こる事から： 事象
- 基本的な事象の1つ1つ： 根元事象
- 根元事象全体の集合： $\Omega = \{\Omega_1, \Omega_2, \dots, \Omega_n\}$
- 試行の結果起こる事象 A ： $A \subseteq \Omega$
- 2つの事象 A と B が同時には起こらないとき、 $A \cap B = \phi$ と書き、2つの事象は互いに排反であるという。
- 根元事象は互いに排反である。
- 事象 A の確率 $P(A) = \frac{n(A)}{n(\Omega)}$; $n(A)$: 事象 A の要素の数

$$P(\Omega) = 1$$

$$P(\phi) = 0$$

Bayesの定理

$H_n (n = 1, \dots, n)$: 排反、網羅的な事象系列

E : 任意の事象

$$P(H_n | E)P(E) = P(E | H_n)P(H_n) = P(H_n, E)$$

従って、 $P(E) \neq 0$ が与えられると、

$$\begin{aligned} P(H_n | E) &= \frac{P(H_n)P(E | H_n)}{P(E)} \\ &= \frac{P(E | H_n)P(H_n)}{\sum_m P(E | H_m)P(H_m)} \\ &\propto P(E | H_n)P(H_n) \end{aligned}$$

確率変数と確率分布

『例』サイコロ

サイコロを振る操作：試行

いずれかの目が出る：根元事象

根元事象に割り当てられた数値：実現値 $\{1, 2, 3, 4, 5, 6\}$

試行にともなって出る目を表す変数 X ：確率変数

確率変数 X の実現値が離散的：離散的確率変数

連続的：連続的確率変数

離散的確率分布

離散的確率変数の各実現値の得られる確率が既知のとき

$$P(\{\Omega_i; X(\Omega_i) = x_i\}) = P(X = x_i) = P_i,$$

$$\sum_{i=1}^n P_i = 1, \quad P_i: \text{確率関数}$$

と表し、確率変数 X に確率分布が与えられているという。

連続的確率分布

確率変数 X の実現値 x が連続な場合、実現値の微小区間を考え、 X の実現値がこの間に入る確率を次のように表す。

$$P(x \leq X \leq x + \delta x) = p(x) \delta x$$

$p(x)$ を確率密度関数といい、 $\int_{-\infty}^{+\infty} p(x) dx = 1$

(累積) 分布関数 $F(x)$

$$F(x) = \sum_{x_i \leq x} P_i$$

離散的確率分布

$$F(x) = \int_{-\infty}^x p(x) dx$$

連続的確率分布

正規分布

ある連続的確率変数 X が平均 μ , 分散 σ^2 の正規分布に従うとき、

$$P(X = x) = p(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-(x-\mu)^2 / 2\sigma^2}$$

であり、 $x \sim N(\mu, \sigma^2)$ と表す。

中心極限定理

同一の分布に従う、互いに独立な N 個の離散的確率変数 X_1, X_2, \dots, X_N の和で表される確率変数の分布は、適当な変数変換と $N \rightarrow \infty$ で、正規分布 $N(0,1)$ となる。

標本抽出と母集団

- 全体から選び出されたもの：標本
- 標本の背後に存在する全体：母集団
- 母集団から標本を抽出する操作：標本抽出

大きな母集団から x_1, x_2, \dots, x_n という値の標本をサンプリング：

➡ 母集団と同じ確率的構造をもつ、互いに独立な n 個の確率変数 X_1, X_2, \dots, X_n が、それぞれ x_1, x_2, \dots, x_n の実現値を持つことと同等。

互いに独立で同一な確率分布に従う n 個の確率変数：

➡ i.i.d.(independent identically distributed)な確率変数

乱数発生法

- 一様乱数: メルセンヌ・ツイスタ法

M.Matsumoto and T.Nishimura, Mersenne twister: A 623 dimensionally equidistributed uniform pseudorandom number generator, ACM Trans. on Modeling and Computer Simulation, 1998

- 正規分布乱数: ボックス・ミュウラ法

2個の一様乱数 r_1, r_2 から, 正規分布 $N(0,1)$ に従う2個の正規乱数 z_1, z_2 を以下の式で発生.

$$z_1 = (-2 \log r_1)^{1/2} \cos 2\pi r_2$$

$$z_2 = (-2 \log r_1)^{1/2} \sin 2\pi r_2$$

$N(\mu, \sigma^2)$ に従う乱数は、変換 $\varsigma_i = \mu + \sigma^2 z_i$ で発生可能.

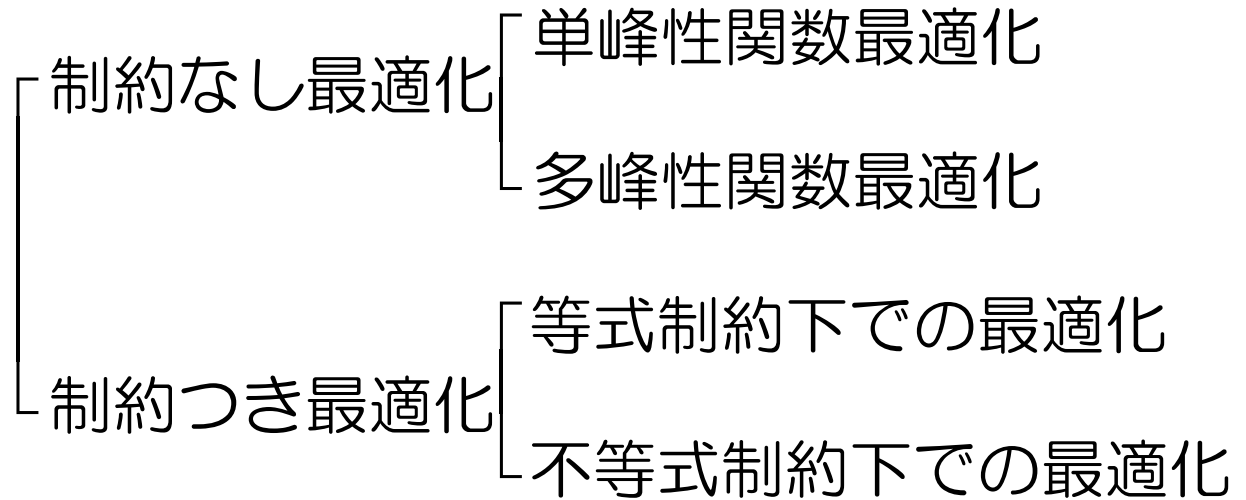
- その他の分布の乱数:

棄却サンプリング、SIR、MCMC等の方法で発生

非線形最適化問題


問題の分類

非線形最適化問題



手法の分類

非線形最適化手法



制約なし非線形最適化問題

〔問題1〕

$$\min_{x \in R^n} : f(x)$$

ここで、 f は R^n 上で定義される非線形関数.

$$f(x^*) \leq f(x) \quad \text{for } \forall x \in R^n$$

が成り立つとき、 x^* を〔問題1〕の**大域的最適解**
(global optimal solution) という。

$$f(x^*) \leq f(x) \quad \text{for } \forall x \in N(x^*, \delta) = \{x \mid \|x^* - x\| \leq \delta\}$$

が成り立つとき、 x^* を〔問題1〕の**局所的最適解**
(local optimal solution) という。

最適性条件

(仮定) $f: R^n \rightarrow R$ は2階連続微分可能とする。
 $\nabla f(\mathbf{x}) = \mathbf{0}$ を満たす点 \mathbf{x}^* : f の停留点(stationary point)


点 \mathbf{x}^* が [問題 1] の局所的最適解ならば, $\nabla f(\mathbf{x}^*) = \mathbf{0}$.

f が凸関数であるとき, 点 \mathbf{x}^* が [問題 1] の大域的
最適解であるための必要条件是, $\nabla f(\mathbf{x}^*) = \mathbf{0}$.

A, B, C, D: 停留点 (stationary point)

A, C: 局所的最適解 (local optimal solution)

C: 大域的最適解 (global optimal solution)



降下方向

$\nabla f(\mathbf{x})^T \mathbf{d} < 0$ なる \mathbf{d} を、
点 \mathbf{x} における f の降下方向と言う。

(n, n) の正定値対称行列 \mathbf{B} に対して

$$\mathbf{d} = -\mathbf{B}\nabla f(\mathbf{x})$$

とすれば、

$$\nabla f(\mathbf{x})^T \mathbf{d} = -\nabla f(\mathbf{x})^T \mathbf{B}\nabla f(\mathbf{x}) < 0 \text{ となる.}$$


従って、 $\mathbf{d} = -\mathbf{B}\nabla f(\mathbf{x})$ は降下方向条件を満たす。

特に、 \mathbf{B} が単位行列のとき、

$$\mathbf{d} = -\nabla f(\mathbf{x})$$

を最急降下方向 (steepest descent direction) と言う。

降下方向の例



勾配法の概要

Step1: 初期探索点 $\mathbf{x}^{(0)}$ を選択. $k = 0$

Step2: 適当な正定値対称行列 $\mathbf{B}^{(k)}$ で降下方向 $\mathbf{d}^{(k)}$ を決定.

$$\mathbf{d}^{(k)} = -\mathbf{B} \nabla f(\mathbf{x}^{(k)})$$

Step3: ステップ幅 $a^{(k)}$ を決定. \Rightarrow 直線探索

$$a^{(k)} = \arg \min_a f(\mathbf{x}^{(k)} + a\mathbf{d}^{(k)})$$

を解き、 $\mathbf{x}^{(k)}$ を更新.


$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + a^{(k)} \mathbf{d}^{(k)}$$

Step4: $\nabla f(\mathbf{x}^{(k+1)}) = 0$ であれば探索終了.

そうでなければ $k = k + 1$ として Step2 へ.

$\mathbf{B}^{(k)}$ が単位行列のとき, **最急降下法** (steepest descent method)

最急降下法の収束性



ニュートン法の概要

Step1 初期探索点 $\mathbf{x}^{(0)}$ を選択. $k = 0$

Step2 正定値行列 $\mathbf{B}^{(k)}$ を, $\mathbf{B}^{(k)} = (\nabla^2 f(\mathbf{x}^{(k)}))^{-1}$ とし,
 $\mathbf{d}^{(k)} = -(\nabla^2 f(\mathbf{x}^{(k)}))^{-1} \cdot \nabla f(\mathbf{x}^{(k)})$ とする.

Step3 ステップ幅 α を, $\alpha^{(k)} = 1$ として,
 $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha^{(k)} \mathbf{d}^{(k)}$

Step4 $\nabla f(\mathbf{x}^{(k+1)}) = 0$ であれば探索終了.
 そうでなければ, $k = k + 1$ としてStep2へ

Step3で, ステップ幅を $\alpha^{(k)} = \arg \min f(\mathbf{x}^{(k)} + \alpha \mathbf{d}^{(k)})$

と直線探索:  直線探索付き α ニュートン法

修正ニュートン法

最適解近傍は凸2次関数で近似可能であり、探索が進めばニュートン法は効率的。しかし、 $(\nabla^2 f(x))^{-1}$ の存在が保証されない。

$\nabla^2 f(x)$ の対角要素に適当な値を加え、正定値化した行列を作成。

➡ 修正ニュートン法 (Levenberg–Marquart法)。


$$\mathbf{d}^{(k)} = -\left\{ (1-\alpha)\nabla^2 f(\mathbf{x}^{(k)}) + \alpha\mathbf{I} \right\}^{-1} \nabla f(\mathbf{x}^{(k)})$$

ここで, $0 \leq \alpha \leq 1$


ニュートン法と最急降下法の混合。

ヘッセ行列の計算が重い。

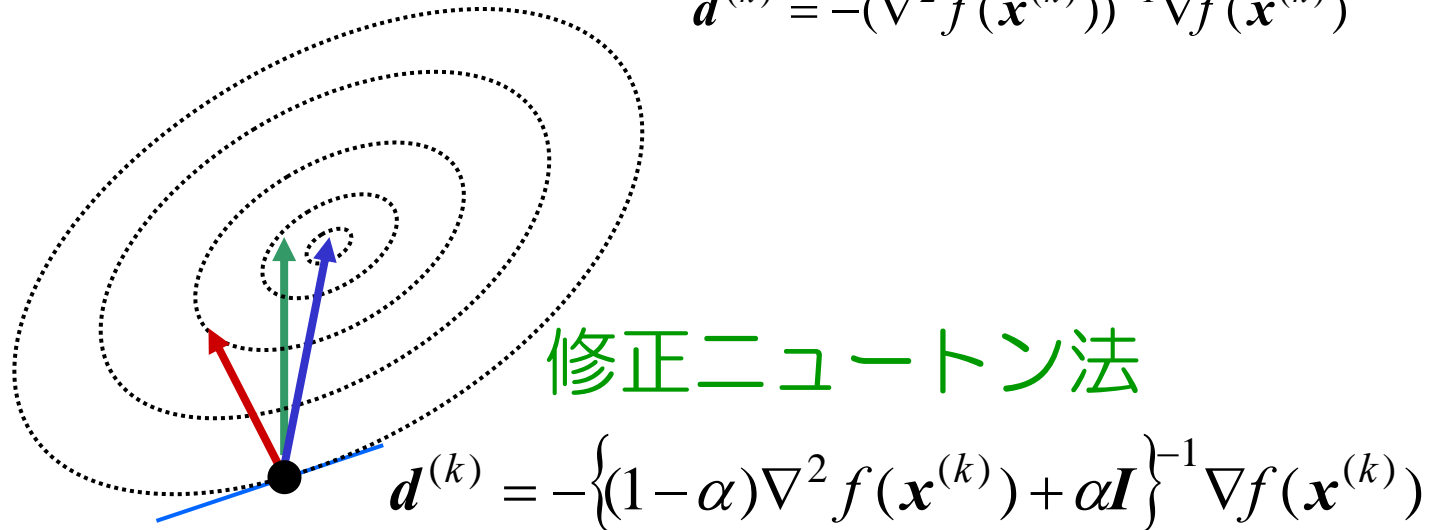
最急降下法



ニュートン法



修正ニュートン法



Fletcher-Reeves法 (共役勾配法)

Step1 初期探索点 $\mathbf{x}^{(0)}$ を選択.

$$\mathbf{d}^{(0)} = -\nabla f(\mathbf{x}^{(0)}), \quad k = 0$$

Step2 $\nabla f(\mathbf{x}^{(k)}) = \mathbf{0}$ ならば終了.

$$\mathbf{d}^{(k)} = -\nabla f(\mathbf{x}^{(k)}) + \frac{\nabla f(\mathbf{x}^{(k)})^T \nabla f(\mathbf{x}^{(k)})}{\nabla f(\mathbf{x}^{(k-1)})^T \nabla f(\mathbf{x}^{(k-1)})} \mathbf{d}^{(k-1)}, \quad k \geq 1$$

Step3 ステップサイズの決定

$$\alpha^{(k)} = \arg \min_{\alpha > 0} f(\mathbf{x}^{(k)} + \alpha \mathbf{d}^{(k)}) \quad \text{を解き,}$$

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha^{(k)} \mathbf{d}^{(k)}, \quad k = k + 1 \quad \text{とする.}$$

Step2へ戻る.

等式制約の下での最適化

〔問題 4 : 等式制約〕

$$\min_{\mathbf{x} \in R^n} f(\mathbf{x}) \quad \text{subj.to} \quad g_i(\mathbf{x}) = 0 \quad (i = 1, \dots, m)$$

ラグランジュ関数

〔問題 4 : 等式制約〕 のラグランジュ関数は

$$L(\mathbf{x}, \boldsymbol{\lambda}) = f(\mathbf{x}) + \sum_{i=1}^m \lambda_i g_i(\mathbf{x}),$$

$\lambda_i (i = 1, \dots, m)$: ラグランジュ乗数

ラグランジュの未定乗数法

〔問題4〕 のラグランジュ関数が \mathbf{x}^* と λ^* で局所的最適解を持つための必要条件は,

$$\nabla_{\mathbf{x}} L(\mathbf{x}, \lambda) \Big|_{\mathbf{x}=\mathbf{x}^*, \lambda=\lambda^*} = \mathbf{0}, \quad \nabla_{\lambda} L(\mathbf{x}, \lambda) \Big|_{\mathbf{x}=\mathbf{x}^*, \lambda=\lambda^*} = \mathbf{0}$$

$$\nabla_{\mathbf{x}} L(\mathbf{x}, \lambda) \Big|_{\mathbf{x}=\mathbf{x}^*, \lambda=\lambda^*} = \nabla f(\mathbf{x}^*) + \sum_{i=1}^m \lambda_i^* \nabla g_i(\mathbf{x}^*) = \mathbf{0}$$

$$\nabla_{\lambda} L(\mathbf{x}, \lambda) \Big|_{\mathbf{x}=\mathbf{x}^*, \lambda=\lambda^*} = (g_i(\mathbf{x}^*), i=1, \dots, m)^T = \mathbf{0}$$

⇒ 〔問題4〕 のKKT条件と等しい.

ラグランジュ未定乗数法（最小化問題）の例

$$\min_{x_1, x_2, x_3} f = x_1^2 + x_2^2 + x_3^2 \quad \text{subj.to} \quad 6x_1 + 2x_2 + 4x_3 = 42$$

ラグランジュ関数は,

$$L(x_1, x_2, x_3, \lambda) = (x_1^2 + x_2^2 + x_3^2) + \lambda(6x_1 + 2x_2 + 4x_3 - 42)$$

最適性条件より

$$\nabla_x L = \begin{pmatrix} 2x_1 \\ 2x_2 \\ 2x_3 \end{pmatrix} + \lambda \begin{pmatrix} 6 \\ 2 \\ 4 \end{pmatrix} = \mathbf{0}, \quad \nabla_\lambda L = 6x_1 + 2x_2 + 4x_3 - 42 = 0.$$

が得られる. 各変数を λ で表し, 制約式に代入すれば,

$$\lambda^* = -\frac{3}{2}. \quad \text{従って, 最適解は } (9/2, 3/2, 3), \text{ 最適値は } 63/2.$$

EMアルゴリズム

EMアルゴリズムとは、不完全データから最尤推定値を求める理論的な枠組み。(1977, Dempster, Laird, Rubin)

不完全データとは、欠損値を含むデータだけでなく、本来観測できない変数（隠れ変数や潜在変数）も含めたデータの総称。

観測データ集合 \mathbf{D} ，隠れ変数集合 \mathbf{Z} ，モデルパラメータ θ とすると、対数尤度関数は

$$L(\mathbf{D}, \theta) = \log p(\mathbf{D} | \theta) = \log \sum_{\mathbf{Z}} p(\mathbf{D}, \mathbf{Z} | \theta)$$

EM法は、対数尤度関数の代わりに、次に示す条件付期待値を逐次的に最大化する。

$$\begin{aligned}
 Q(\boldsymbol{\theta} | \boldsymbol{\theta}^{(t)}) &= E_{\mathbf{Z}} \{ \log p(\mathbf{D}, \mathbf{Z} | \boldsymbol{\theta}) | \mathbf{D}, \boldsymbol{\theta}^{(t)} \} \\
 &= \sum_{\mathbf{Z}} P(\mathbf{Z} | \mathbf{D}, \boldsymbol{\theta}^{(t)}) \log p(\mathbf{D}, \mathbf{Z} | \boldsymbol{\theta})
 \end{aligned}$$

θ に関して以下のように逐次的に最大化を行う.


EMアルゴリズム

Step1. 初期値 $\theta^{(0)}$ を設定し, $t \leftarrow 0$ とする.

Step2. 収束するまで以下の処理を繰り返す.

E - step: $Q(\theta | \theta^{(t)})$ を計算.

M - step: $\theta^{(t+1)} = \arg \max_{\theta} Q(\theta | \theta^{(t)})$ とし, $t \leftarrow t+1$ とする.

Q 関数の最大化  対数尤度の最大化 (最尤法)

正規混合分布の最尤推定

正規混合分布： m 個の正規分布の混合からなる分布


$$p(\mathbf{x} | \boldsymbol{\theta}) = \sum_{i=1}^m \alpha_i N(\mathbf{x}; \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i), \quad \text{ただし, } \sum_{i=1}^m \alpha_i = 1$$

$N(\cdot; \boldsymbol{\mu}, \boldsymbol{\Sigma})$ は、平均ベクトル $\boldsymbol{\mu} \in R^d$, 共分散行列 $\boldsymbol{\Sigma} \in R^{d \times d}$ を持つ多次元正規分布.


$$N(\mathbf{x}; \boldsymbol{\mu}, \boldsymbol{\Sigma}) = (2\pi)^{-d/2} |\boldsymbol{\Sigma}|^{-1/2} \exp\left\{-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right\}$$

観測データ集合 $\mathbf{D} = \{\mathbf{x}_j\}_{j=1}^N$ から、最尤法によって
未知パラメータ $\boldsymbol{\theta} = \{\alpha_i, \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i\}_{i=1}^m$ を推定する問題.

画像の統計モデル




m 個の正規分布の混合分布
として画像が存在 (仮定)



多変量混合正規分布モデル

$$p(\mathbf{x} | \boldsymbol{\theta}) = \sum_{i=1}^m \alpha_i N(\mathbf{x}; \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i)$$



EMアルゴリズムによる推定

隠れ変数 $z_i \in \mathbf{Z} = \{z_j\}_{j=1}^N$ は、観測データ \mathbf{x}_i がどの混合成分から発生したのかを示す指標で、 $\{1, \dots, m\}$ のいずれかの値をとる。

$$P(z_n = i \mid \mathbf{x}_n, \boldsymbol{\theta}^{(t)}) = \frac{p(\mathbf{x}_n, z_n = i \mid \boldsymbol{\theta}^{(t)})}{p(\mathbf{x}_n \mid \boldsymbol{\theta}^{(t)})} = \frac{p(\mathbf{x}_n, z_n = i \mid \boldsymbol{\theta}^{(t)})}{\sum_{i=1}^m p(\mathbf{x}_n, z_n = i \mid \boldsymbol{\theta}^{(t)})}$$

$$p(\mathbf{x}_n, z_n = i \mid \boldsymbol{\theta}) = \alpha_i N(\mathbf{x}_n; \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i)$$

より,

$$\begin{aligned} Q(\boldsymbol{\theta} \mid \boldsymbol{\theta}^{(t)}) &= \sum_{i=1}^m \sum_{n=1}^N P(z_n = i \mid \mathbf{x}_n, \boldsymbol{\theta}^{(t)}) \log p(\mathbf{x}_n, z_n = i \mid \boldsymbol{\theta}) \\ &= \sum_{i=1}^m \sum_{n=1}^N \frac{\alpha_i^{(t)} N(\mathbf{x}_n; \boldsymbol{\mu}_i^{(t)}, \boldsymbol{\Sigma}_i^{(t)})}{\sum_{j=1}^m \alpha_j^{(t)} N(\mathbf{x}_n; \boldsymbol{\mu}_j^{(t)}, \boldsymbol{\Sigma}_j^{(t)})} \log \{\alpha_i N(\mathbf{x}_n; \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i)\} \end{aligned}$$

M - step : 等式拘束条件($\sum_{i=1}^m \alpha_i = 1$)つき $Q(\theta | \theta^{(t)})$ の最大化.

→ ラグランジュの未定乗数法による解法

$G(\theta, \lambda) = Q(\theta | \theta^{(t)}) + \lambda(\sum_{i=1}^m \alpha_i - 1)$ として (ラグランジュ関数)

$$\nabla_{\theta} G(\theta, \lambda) |_{\theta=\theta^*, \lambda=\lambda^*} = \mathbf{0}, \quad \nabla_{\lambda} G(\theta, \lambda) |_{\theta=\theta^*, \lambda=\lambda^*} = 0$$

を満たす (θ^*, λ^*) を求める.

これを各成分毎に表すと,

$$\frac{\partial Q(\theta | \theta^{(t)})}{\partial \mu_i} = 0, \quad \frac{\partial Q(\theta | \theta^{(t)})}{\partial \Sigma_i^{-1}} = 0, \quad \frac{\partial G(\theta, \lambda)}{\partial \alpha_i} = 0$$

が条件となる.

以上のことを踏まえると，以下の更新式が得られる。

$$\boldsymbol{\mu}_i^{(t+1)} = \frac{1}{N_i^{(t)}} \sum_{n=1}^N P(z_n = i \mid \mathbf{x}_n, \boldsymbol{\theta}^{(t)}) \mathbf{x}_n,$$

$$\boldsymbol{\Sigma}_i^{(t+1)} = \frac{1}{N_i^{(t)}} \sum_{n=1}^N P(z_n = i \mid \mathbf{x}_n, \boldsymbol{\theta}^{(t)}) \mathbf{V}_{ni}^{(t+1)},$$

$$\alpha_i^{(t+1)} = \frac{N_i^{(t)}}{N}$$

ただし， $\mathbf{V}_{ni}^{(t+1)} = (\mathbf{x}_n - \boldsymbol{\mu}_i^{(t+1)})(\mathbf{x}_n - \boldsymbol{\mu}_i^{(t+1)})^T,$

$$N_i^{(t)} = \sum_{n=1}^N P(z_n = i \mid \mathbf{x}_n, \boldsymbol{\theta}^{(t)})$$

$\alpha_i^{(0)}, \boldsymbol{\mu}_i^{(0)}, \boldsymbol{\Sigma}_i^{(0)}$ に適当な初期値を与え，上記反復処理を実行。