

# MAP-MRFに基づく最適化(I)

# ビジョン問題：その性質

## 1. 問題の表現

ラベル集合 $L$ の連続性

{ 連続（離散）問題  
組合せ問題

## 2. 目的関数

解 $f$ が探索空間内で制約  
を受けるか否か


{ 制約なし問題  
制約つき問題

## 3. 最適化アルゴリズム

局所的探索か、それとも  
大局的探索か

{ Local Method  
Global Method

# ビジョン問題に対する最適化手法

- 尤度最大化  EM法

- 事後確率最大化 (MAP: エネルギー最小化)

 勾配法や変分法, Lagrange未定乗数法  
各種のMAP-MRF法


- Relaxation Labeling法
- Iterated Conditional Mode(ICM)法
- Metropolis sampling and Gibbs sampling法
- Mean Field法, Belief Propagation法 など.

# 最大尤度推定による画像分割

〔資料9参照〕



原画像



初期分割画像  
(K-mean法；4クラスタ)



EM法による最尤推定結果  
(4混合分布によるモデル化)

# 勾配法と最小化問題

## 勾配法の概要（エネルギー最小化）

MAP解  $\mathbf{f}^* = \arg \min_{\mathbf{f}} E(\mathbf{f})$ を求める最も単純な方法は勾配法。初期値  $\mathbf{f}^{(0)}$ から始め、

$$\mathbf{f}^{(t+1)} \leftarrow \mathbf{f}^{(t)} - \mu \nabla E(\mathbf{f}^{(t)}),$$

( $\mu$ はステップ刻み)

を  $\nabla E(\mathbf{f}^{(t)}) = \mathbf{0}$  となる点まで繰り返す。

$\nabla E(\mathbf{f}^{(t)}) = \mathbf{0}$ を与えるラベルを  $\mathbf{f}^*$  とすると、

$\mathbf{f}^*$  は局所的最小解。

# 連続ラベルのエネルギー関数最小化

連続ラベル集合  $L$  におけるラベル  $f \in F$  の連続復元問題の事後エネルギー  $E(f)$  は,

サイト集合 :  $S = \{(x, y) \mid 1 \leq x, y \leq n\}$ ,

近傍系 :  $N_{(x,y)}$  サイト  $(x, y)$  の近傍集合

とすると,

$$\begin{aligned} E(f) &= U(d \mid f) + U(f) \\ &= \sum_{x,y} (f_{x,y} - d_{x,y})^2 + \lambda \sum_{x,y} \sum_{(k,l) \in N_{(x,y)}} g(f_{x,y} - f_{k,l}) \end{aligned}$$

$g(\cdot)$  はペナルティ関数

$g'(\eta) = 2\eta h(\eta)$ と仮定すると, サイト $(x, y)$ におけるラベル  
勾配 $\nabla_{f_{x,y}} E(f)$ は,

$$\frac{\partial E}{\partial f_{x,y}} = 2(f_{x,y} - d_{x,y}) + 2\lambda \sum_{(k,l) \in N_{(x,y)}} (f_{x,y} - f_{k,l}) h(f_{x,y} - f_{k,l})$$

勾配法の局所的最小解条件 $\nabla E(\mathbf{f}^*) = 0$ を満たす $\mathbf{f}^*$ を得る  
ために, 以下の反復式を各サイト毎に実行.

$$f_{x,y}^{(t+1)} \leftarrow f_{x,y}^{(t)} - 2\mu \{ (f_{x,y}^{(t)} - d_{x,y}) + \lambda \sum_{(k,l) \in N_{(x,y)}} (f_{x,y}^{(t)} - f_{k,l}^{(t)}) h(f_{x,y}^{(t)} - f_{k,l}^{(t)}) \}$$

$\mu$  は, ステップ幅を決定 する定数

# オプティカルフロー問題

## オプティカルフロー：

観察者の移動とシーン中の物体の移動によって生じる画像面内のベクトル場

→ 領域と境界の分割、形状復元などの重要な情報を含む.

## フロー計算の2つのパラダイム

- { 特徴に基づく方法…局所的なベクトル場
- { 濃度勾配に基づく方法…画像全体のベクトル場



点 $(x, y)$ , 時刻  $t$  における画像の明るさを  $I(x, y, t)$  とする.  
このとき, 明るさ不変 の拘束条件を仮定:

(拘束A)

移動する点の明るさは, 時刻  $t$  と  $t + \delta t$  の間で不変.

$$I(x, y, t) = I(x + \delta x, y + \delta y, t + \delta t)$$

$I(x + \delta x, y + \delta y, t + \delta t)$  の  $(x, y, t)$  における 1 次のTaylor展開  
と拘束A,  $\delta t \rightarrow 0$  より, 以下の関係が導かれる.

$$\frac{\partial I}{\partial x} \frac{dx}{dt} + \frac{\partial I}{\partial y} \frac{dy}{dt} + \frac{\partial I}{\partial t} = 0$$

$$\nabla I = \begin{pmatrix} I_x \\ I_y \end{pmatrix} = \begin{pmatrix} \partial I / \partial x \\ \partial I / \partial y \end{pmatrix}, I_t = \frac{\partial I}{\partial t}, \mathbf{v} = \begin{pmatrix} v_x(x, y) \\ v_y(x, y) \end{pmatrix} = \begin{pmatrix} dx / dt \\ dy / dt \end{pmatrix}$$

とおくと、オプティカルフロー $\mathbf{v}$ の基本式は

$$v_x \cdot I_x + v_y \cdot I_y + I_t = \nabla I \cdot \mathbf{v} + I_t = 0$$

画像観測の関係上、誤差が含まれる。さらに、オクルージョンや動きの不連続などが存在。

→ 事後エネルギーの最小化問題  
(尤度エネルギー + 事前エネルギー)

- 尤度（観測データのらしさ）エネルギー：

$$U(I | \mathbf{v}) = (\nabla I \cdot \mathbf{v} + I_t)^2$$

- 事前エネルギー：フローの滑らかさ

→ フロー勾配の大きさの2乗で拘束を表現

$$\begin{aligned}
 U(\mathbf{v}) &= \|\nabla v_x\|^2 + \|\nabla v_y\|^2 \\
 &= \left(\frac{\partial v_x}{\partial x}\right)^2 + \left(\frac{\partial v_x}{\partial y}\right)^2 + \left(\frac{\partial v_y}{\partial x}\right)^2 + \left(\frac{\partial v_y}{\partial y}\right)^2
 \end{aligned}$$

従って、事後エネルギー  $E(\mathbf{v}) = U(\mathbf{v} | I)$  は

$$E(\mathbf{v}) = U(\mathbf{v} | I) = U(I | \mathbf{v}) + \lambda U(\mathbf{v}) \quad \lambda \text{ は重み係数}$$

$$= (\nabla I \cdot \mathbf{v} + I_t)^2 + \lambda \{\|\nabla v_x\|^2 + \|\nabla v_y\|^2\}$$

(Horn-Schunck's method)

→ 事後エネルギー  $E(\mathbf{v})$  を最小化する  $\mathbf{v}^*$  の計算.

# デジタル画像におけるフロー計算

サイト  $(i, j)$  における尤度エネルギー  $c(i, j)$

$$c(i, j) = [I_x(i, j)v_x(i, j) + I_y(i, j)v_y(i, j) + I_t(i, j)]^2$$

サイト  $(i, j)$  での事前エネルギー  $s(i, j)$  は,

$$\begin{aligned} s(i, j) = & \frac{1}{4}[(v_x(i, j) - v_x(i-1, j))^2 + (v_x(i+1, j) - v_x(i, j))^2 \\ & + (v_x(i, j+1) - v_x(i, j))^2 + (v_x(i, j) - v_x(i, j-1))^2 \\ & + (v_y(i, j) - v_y(i-1, j))^2 + (v_y(i+1, j) - v_y(i, j))^2 \\ & + (v_y(i, j+1) - v_y(i, j))^2 + (v_y(i, j) - v_y(i, j-1))^2] \end{aligned}$$

従って、最適フロー推定  $\mathbf{v}^*$  は,

$$\mathbf{v}^* = \arg \min_{\mathbf{v}} \sum_i \sum_j [c(i, j) + \lambda s(i, j)]$$

$$\text{最適フロー, } \mathbf{v}^* = \left\{ \begin{pmatrix} v_x^*(1,1) \\ v_y^*(1,1) \end{pmatrix}, \begin{pmatrix} v_x^*(1,2) \\ v_y^*(1,2) \end{pmatrix}, \dots, \begin{pmatrix} v_x^*(n,n) \\ v_y^*(n,n) \end{pmatrix} \right\}$$

$$\text{の必要条件より, } \frac{\partial E}{\partial v_x(i,j)} = 0, \quad \frac{\partial E}{\partial v_y(i,j)} = 0$$

$$\begin{aligned} \Rightarrow \quad & 2(v_x(i,j)I_x + v_y(i,j)I_y + I_t)I_x + 2\lambda(v_x(i,j) - \bar{v}_x(i,j)) = 0 \\ & 2(v_x(i,j)I_x + v_y(i,j)I_y + I_t)I_y + 2\lambda(v_y(i,j) - \bar{v}_y(i,j)) = 0 \end{aligned}$$

ここで,  $\bar{v}_x, \bar{v}_y$  は  $v_x, v_y$  の局所的平均値を表し,

$$\bar{v}_x(i,j) = 1/4 \{v_x(i-1,j) + v_x(i+1,j) + v_x(i,j-1) + v_x(i,j+1)\}$$

$$\bar{v}_y(i,j) = 1/4 \{v_y(i-1,j) + v_y(i+1,j) + v_y(i,j-1) + v_y(i,j+1)\}$$

整理すると,

$$[\lambda + (I_x)^2]v_x + I_x I_y v_y = \lambda \bar{v}_x - I_x I_t$$

$$I_x I_y v_x + [\lambda + (I_y)^2]v_y = \lambda \bar{v}_y - I_y I_t$$

オプティカルフローの解は、Gauss - Seidel法に基づいた連立方程式の反復解として

$$v_x^{k+1} \leftarrow \bar{v}_x^k - \left[ \frac{(I_x)\bar{v}_x^k + (I_y)\bar{v}_y^k + I_t}{\lambda + (I_x)^2 + (I_y)^2} \right] I_x$$

$$v_y^{k+1} \leftarrow \bar{v}_y^k - \left[ \frac{(I_x)\bar{v}_x^k + (I_y)\bar{v}_y^k + I_t}{\lambda + (I_x)^2 + (I_y)^2} \right] I_y$$

と与えられる。

値の変化がなくなるまで更新を繰り返す。

# 離散ラベルのエネルギー関数最小化

ラベル集合が離散的な場合，事後エネルギーの最小化は組合せ問題となる．

MRFにおける各ラベルの結合確率を最大化することは困難である．

⇒ greedyな戦略（局所的最適化）：ICM法

すべての変数が同時には関係しない最適化問題である場合，逐次的最適化問題として表現する．

⇒ DP法が有効．

# Iterative Conditional Modes法 (ICM法) [Besag, J(1986)]

$$\left. \begin{aligned} \text{密度関数: } p(\mathbf{d} | \mathbf{f}) &= \prod_i p(d_i | f_i) \\ P(f_i | d_i, f_{N_i}) &\propto p(d_i | f_i) P(f_i | f_{N_i}) \end{aligned} \right\}$$

を仮定.

$P(f_i | d_i, f_{N_i})$ の最大化

$\Rightarrow$  条件付エネルギー  $V(f_i | d_i, f_{N_i})$   
の最小化

ただし,

$$V(f_i | d_i, f_{N_i}^{(k)}) = V(d_i | f_i) + \sum_{j \in N_i} V(f_i | f_j^{(k)})$$

$$\begin{aligned} &P(f_i | d_i, f_{N_i}) \\ &= \frac{P(f_i, d_i, f_{N_i})}{P(d_i)P(f_{N_i})} \\ &= \frac{p(d_i | f_i, f_{N_i})P(f_i | f_{N_i})P(f_{N_i})}{P(d_i)P(f_{N_i})} \\ &= \frac{p(d_i | f_i)P(f_i | f_{N_i})}{P(d_i)} \\ &\propto p(d_i | f_i)P(f_i | f_{N_i}) \end{aligned}$$



→ 反復式  $f_i^{(k+1)} \leftarrow \arg \min_{f_i} V(f_i | d_i, f_{N_i}^{(k)})$  を利用.

例えば, 区分的一定な面の復元問題に対しては,

$$V(f_i | d_i, f_{N_i}) = \frac{(f_i - d_i)^2}{\sigma^2} + v_{20} \sum_{j \in N_i} [1 - \delta(f_i - f_j)]$$

各サイトに対して反復式を適用. すべてのサイトが収束するまでICMサイクルを繰り返す.

初期値  $f^{(0)}$  としては, 通常  $f^{(0)} = d$  (観測値) を用いることが多い.

# Dynamic Programming法

ポテンシャルエネルギーが,

$$E(f_1, f_2, \dots, f_m)$$

$$= E_1(f_1, f_2) + E_2(f_2, f_3) + \dots + E_{m-1}(f_{m-1}, f_m)$$

のように表されると仮定.

$$D_1(f_2) = \min_{f_1} E_1(f_1, f_2)$$

$$D_2(f_3) = \min_{f_2} [D_1(f_2) + E_2(f_2, f_3)]$$

$$\vdots$$

$$D_{m-1}(f_m) = \min_{f_{m-1}} [D_{m-2}(f_{m-1}) + E_{m-1}(f_{m-1}, f_m)] \quad \text{とすると,}$$

最小解  $\min_f E(f)$  は, 以下のように表される.

$$\min_{f_1, \dots, f_m} E(f_1, f_2, \dots, f_m) = \min_{f_m} D_{m-1}(f_m)$$

# 領域分割問題 (例 1)

ガウス性雑音を含む領域をMLLモデルで表し、画像の領域分割を行う方法(Derin - Elliot法).

$S = \{(i, j) | 1 \leq i, j \leq m\}$ ,  $L = \{l_1, l_2, \dots, l_M\}$ として、事後エネルギーを

$$E(f) = U(f | d) = \sum_{c \in C} V_c(f) + \sum_{I \in L} \sum_{(i, j) \in S^{(I)}} \frac{1}{\sigma^2} (d_{i, j} - l_I)^2$$

$$= \sum_{k=1}^{m-1} E_k(f_k, f_{k+1}) = \sum_{k=1}^{m-1} \left\{ \sum_{c \in C^{k, k+1}} V_c(f) + \sum_{I \in L} \sum_{S_I^k} \frac{1}{\sigma^2} (d_{i, j} - l_I)^2 \right\}$$

と分解. ただし,  $f_k, f_{k+1}$ は  $k, k+1$ 行のラベルを表し,

$S_I^k = \{(k, j) | f_{k, j} = l_I, 1 \leq j \leq m\}$ を表す.

⇒ DPによる最小化

# 輪郭線抽出問題 (SNAKES)(例2)


動的輪郭モデル(Active Contour Model) [Kass et.al.]

エネルギー（評価関数）の導入とその最小化を行うために、輪郭線をパラメータ表現.

サイト（制御点）集合：

$$\mathbf{v} = (v_1, v_2, \dots, v_n)$$

不規則サイト集合



エネルギー関数： $E_{snakes}$

⇒ 事後エネルギーとして定式化可能.


$$\begin{aligned} E_{snakes}(\boldsymbol{v}) &= E_{\text{int}}(\boldsymbol{v}) + E_{\text{ext}}(\boldsymbol{I} | \boldsymbol{v}) \\ &= \sum_{i=1}^n E_{\text{int}}(v_i) + \sum_{i=1}^n E_{\text{ext}}(\boldsymbol{I} | v_i) \end{aligned}$$

$E_{\text{int}}(\boldsymbol{v})$ : 配置  $\boldsymbol{v}$  の事前 (内部) エネルギー

$E_{\text{ext}}(\boldsymbol{I} | \boldsymbol{v})$ : 観測画像  $\boldsymbol{I}$  の配置  $\boldsymbol{v}$  に対する  
尤度(画像) エネルギー

$$E_{\text{int}}(v_i) = \alpha |\dot{v}_i| + \beta |\ddot{v}_i|$$

$$\dot{v}_i = v_i - v_{i-1}, \quad \ddot{v}_i = \dot{v}_{i+1} - \dot{v}_i$$



$$E_{\text{ext}}(I | v_i) = -\gamma \cdot |\nabla_{v_i} I(x, y)|$$

$$\nabla_{v_i} I(x, y):$$


サイト  $v_i$  の位置での  
画像  $I$  の濃度勾配

$$E_{\text{snakes}}(\mathbf{v}) = E(v_1, v_2, \dots, v_n)$$


$$= E_1(v_1, v_2, v_3) + E_2(v_2, v_3, v_4) + \dots + E_n(v_n, v_1, v_2)$$

と表現可能.  $\Rightarrow$  DPの利用.


## 動的輪郭線処理の例



積み木画像



初期制御点配置  
(手動による指定)



収束後制御点配置

# 弛緩法（エッジ強調問題の例）

## 弛緩法(Relaxation Labeling)

エッジの強さと方向に基づく確率的反復法

エッジ(サイト) 集合  $S = \{1, 2, \dots, n\}$

エッジラベル集合  $\Lambda = \{\lambda_1, \lambda_2, \dots, \lambda_m\}$

サイト  $i$  がラベル  $\lambda_u$  を持つ確率  $P_i(\lambda_u)$

$$\sum_{\lambda_u} P_i(\lambda_u) = 1, \quad i \in S$$

$$P_i(\lambda_u) \geq 0, \quad \forall i, \lambda_u$$



# 適合関数(compatibility function)

単項適合関数  $r_i(\lambda_u) = C_1 - V_1(\lambda_u)$

2項適合関数  $r_{ij}(\lambda_u, \lambda_v) = C_2 - V_2(\lambda_u, \lambda_v)$

$V_1(\lambda_u)$  単一サイトクリークポテンシャル

$V_2(\lambda_u, \lambda_v)$  ペアサイトクリークポテンシャル

ラベル配置  $f$  のゲイン  $G(f) : (= C_0 - E(f))$

$$G(f) = \sum_{i \in S} \sum_{\lambda_u \in \Lambda} r_i(\lambda_u) P_i(\lambda_u) + \\ \sum_{i \in S} \sum_{\lambda_u \in \Lambda} \sum_{j \in S, j \neq i} \sum_{\lambda_v \in \Lambda} r_{ij}(\lambda_u, \lambda_v) P_i(\lambda_u) P_j(\lambda_v)$$

事後エネルギー  $E(f)$  の最小化  $\Rightarrow G(f)$  の最大化

## $G(f)$ の最大化

勾配  $\mathbf{q} = -\nabla E(f) = \{q_i(\lambda_u) \mid i \in \mathcal{S}, \lambda_u \in \mathcal{A}\}$  を利用.

各  $q_i(\lambda_u)$  は、

$$q_i(\lambda_u) = \frac{\partial G}{\partial P_i(\lambda_u)} = r_i(\lambda_u) + 2 \sum_{j \in \mathcal{S}} \sum_{\lambda_v \in \mathcal{A}} r_{ij}(\lambda_u, \lambda_v) P_j(\lambda_v)$$

ここで、 $P_i^{(t)}(\lambda_u) = P_i(\lambda_u)$  とし、サイト  $i$  が時刻  $t$  でラベル  $\lambda_u$  を持つ確率とする.

$P^{(t)}$  を、 $P^{(t)}$  と  $q^{(t)}$  に基づいて更新.


$$P^{(t+1)} \leftarrow \Phi(P^{(t)}, q^{(t)})$$

$\Phi$  は、更新操作を表し、個々のアルゴリズム毎に定義される。(多数のアルゴリズムの存在)

• 確率の更新例 (Rosenfeld et. al., 1976)

$$P_i^{(k+1)}(\lambda_u) = \frac{P_i^{(k)}(\lambda_u)[1 + q_i^{(k)}]}{\sum_{\lambda_u} \{P_i^{(k)}(\lambda_u)[1 + q_i^{(k)}]\}}$$

$$q_i^{(k)} = \sum_j d_{ij} [\sum_{\lambda_v} r_{ij}(\lambda_u, \lambda_v) P_j^{(k)}(\lambda_v)]$$



ラベル間の適合度(compatibility)係数の例


# 弛緩法によるエッジ強調例



原画像



微分画像



繰返し：2回、閾値：0.7



繰返し：3回、閾値：0.7



繰返し：4回、閾値：0.7



繰返し：5回、閾値：0.7



繰返し：8回、閾値：0.7

## 主な参考文献

S.Z.Li, Markov Random Field Modeling in Computer Vision, Springer-Verlag, (1995)

Horn, B.K.P and Schunck, B.G., "Determining Optical Flow," Artificial Intelligence, vol.17, nos.1--3, pp.185-- 203, (1981).

Besag, J. ; “On the statistical analysis of dirty pictures”, *Journal of the Royal Statistical Society, Series B*, 48, pp.259—302 (1986).

M. Kass, A. Witkin, and D. Terzopoulos; “Snakes: Active contour models” In Proc. 1st Int. Conf. on Computer Vision, pp. 259--268, (1987).

A. Rosenfeld, R.A. Hummel and S.W. Zucker, Scene Labelling by Relaxation Operations, IEEE Trans. on SMC, 6, pp.420--433, (1976)

上田修功, ベイズ学習[I] —統計的学習の基礎—, 電子情報通信学会誌, vol.85, No.4, pp.265-271, (2002)